

当 AI 学会“看懂”商业视频：OmniVideo-100K 与未来的商业智能

这篇来自南京大学和中科院自动化所的论文，讲的其实是一个很多人关注的问题：现在的 AI 看视频，为什么总是“看了等于白看”？

传统方法处理音视频的方式很“笨”——把视频切成 15 秒的小段，画面单独描述，声音单独转录，最后拼在一起让 AI 理解，这种碎片化处理让 AI 只能理解局部发生了什么，而无法把握整个故事所要表达的内容。OmniVideo-100K 的核心贡献，就是给 AI 配了一个“编剧”。它通过两个关键机制解决上述问题：第一，“**实体锚定脚本化**”——先让 AI 看完整个视频，提炼出主要角色，然后在所有片段描述中统一使用这个称呼，确保叙事的连贯性。第二，“**线索引导式问答生成**”——不让 AI 直接编问题，而是先让它在整个视频脚本里寻找线索，找出那些跨越多个片段、需要音画结合才能回答的问题，然后再针对这些线索生成问答对。

实验数据很能说明问题。在 OmniVideo-100K 上微调后的模型，在自建测试集上性能提升了超过 20%，而外部基准测试 Daily-Omni 的“音视频事件对齐”任务上更是暴涨了 17%。这意味着 AI 真的学会了把声音和画面在时间轴上对应起来——当听到一声巨响，它会去看画面里是否有什么东西爆炸了，而不是像以前一样乱猜。

先说最直接的——投研分析。

现在的 AI 看财报电话会，基本靠语音转文字，然后把文字扔进大模型分析。但问题是，会议中人们的语气以及参会人员的各种反应，这些信息全在画面和声音的细节里，但现有的 AI 根本抓不住。

OmniVideo-100K 的技术如果迁移过来，AI 就能做到：识别出 CEO、CFO 等实体，跟踪他们在整个会议中的微表情变化，把“他说了什么”和“他什么表情说的”关联起来，甚至能跨时间段对比——三个月前他说同样的话时是什么状态，现在有什么不同。这对判断上市公司管理层的真实信心，比单纯读文字 transcripts 要靠谱得多。

论文里提到，传统方法在“细粒度时序对齐”任务上表现很差——**AI 分不清某个声音到底对应哪一帧画面，但 OmniVideo-100K 恰恰擅长解决这个问题。**放在金融场景里，这意味着 AI 可以精确识别出：当某只股票的异动新闻被播报时，屏幕上的 K 线图可以同步出现异常波动，这个“声音-画面-数据”的三维对齐能力，对量化交易中的新闻驱动策略可能是革命性的。

再往大了想——实体店和消费洞察。

论文里有个细节让我印象很深：他们用“主实体列表”来确保同一个角色在不同片段中被一致描述。这个思路迁移到零售场景，就是给每个进店的顾客建立一个实体档案——不只是人脸识别，还包括他的行走路线、停留时长、与哪些商品有过交互。

更妙的是声音的利用。论文花了很大篇幅处理“非语音声音”——比如脚步声、环境音等，在实体店里，这些声音其实是极其丰富的信号：某个货架前的脚步声突然变密集，说明客流聚集；收银台前的等待时间声音特征变化，暗示排队过长。把这些声音和视觉信息关联起来，AI 可以实时感知门店的运营状态，而不仅仅是事后看监控回放。

还有风控和合规场景。

金融机构有大量的视频监控和录音数据——柜面交易录像、电话销售录音、客户面访视频，现在的合规检查基本靠人工抽检，效率极低。但如果 AI 能做到论文中展示的那种“跨片段因果推理”——把前面几十分钟的对话和画面线索串联起来，判断某个违规行为的发生是否有迹可循，那合规监测就可能从“事后抽查”变成“实时预警”。

论文里有个实验数据：他们对比了“直接生成问答”和“线索引导式生成”两种方式，发现后者生成的问答平均时间跨度达到 144 秒，而前者只有 76 秒。这意味着引导式让 AI

真正去理解剧情，而不是只看眼前。在风控场景中，很多违规行为恰恰是剧情层面的——它不是孤立事件，而是一系列看似正常的小动作累积的结果。只有真正把握剧情的 AI，才能提前嗅到风险。

当然，也要泼点冷水。

论文坦诚地指出，他们在处理非语音音效时表现反而下降，因为脚本描述太笼统，这让我想到一个很现实的问题：商业场景里的声音往往更复杂。一个嘈杂的交易所、一个拥挤的零售卖场，背景音里可能混着几十种信号，现有的 AI 根本分不清哪个是重要的。另外，论文使用的视频平均时长只有 103 秒，而真实的商业视频——比如一场完整的分析师会议，动辄一两个小时，虽然他们在部分实验中测试了 8-14 分钟的视频，但距离处理真正的长视频还有距离。

我的核心观点是： OmniVideo-100K 这篇论文最大的价值，不是它提升了多少准确率，而是它示范了一种思维方式——AI 理解视频，不应该像瞎子摸象那样一个片段一个片段地摸，而应该像读剧本一样把握全局、像侦探一样追踪线索。这种思维方式一旦迁移到商业领域，可能会催生出一批真正看懂商业场景的 AI——从更聪明的投研助手，到更敏锐的门店管理系统，再到更可靠的风控预警工具。

当然，技术落地从来不只是技术问题，隐私、合规、成本——这些都是现实阻碍，但方向已经很明确了：未来的商业智能，一定是属于那些能同时“看懂”画面、“听清”声音、并且“理解”剧情的 AI。而 OmniVideo-100K，正在为这个未来铺第一块砖。

参考文献： Cai X Y, Fu C Y, Zhang Y F, et al.

OmniVideo-100K: A dataset for audio-visual reasoning through structured scripts and evidence chains[J/OL]. arXiv preprint, 2026.

<https://arxiv.org/abs/2606.14702>.

deepseek:

15:57

新对话

2606.14702v2.pdf

根据表6显示，为什么模型在音乐和语音样本上进行了改善，但在声音类别上的性能却下降？

根据论文正文（第9页）中作者对表6结果的分析，这个“偏科”现象的核心原因在于数据生成策略中对不同音频类型采用了差异化的描述方式。

作者给出的官方解释可以拆解为两个层面：

1. 为什么音乐和语音强点了？

- 语音：有精准的逐字稿（ASR转录文本），信息密度极高，模型能学到具体的语义内容。
- 音乐：论文要求模型对音乐进行详细描述（比如“激昂的交响乐”），保留了丰富的声学特征。这两种模式都有高质量、细粒度的文本描述，模型微调后自然强点。

2. 为什么音效（Sound）类反降了4.21%？

- 论文在生成脚本时，对非语音音效（如狗叫、刹车声、玻璃碎裂）采取了完全不同的策略——只能用粗粒度的通用类别词来描述（比如只写“机械噪音”、“撞击声”或“动物叫声”）。
- 这样做的目的是“避免过度推测”——因为仅凭音频很难100%确定声音的具体来源，强行细描可能引入幻觉。
- 但代价就是：脚本里关于音效的文本信息极其模糊，而QA生成又完全依赖脚本本来“出题”和“找答案”，既然脚本文本对音效的描述都是“大概是什么”，模型在学习时就抓不到精细的声学特征，遇到需要区分“刹车声”和“引擎轰鸣声”的问题时，自然就答不对了。

一句话总结：语音有“逐字稿”，音乐有“详细描述”，而音效只得了一个“粗略标签”。训练数据质量不均，模型就学会了偏科——它擅长处理那些在脚本里写得清楚的内容，而对那些写得模糊的声音类别，能力反而退步了。

发消息或按住说话

深度思考 智能搜索

15:58

新对话

“激昂的交响乐”，保留了丰富的声学特征。这两种模式都有高质量、细粒度的文本描述，模型微调后自然强点。

2. 为什么音效（Sound）类反降了4.21%？

- 论文在生成脚本时，对非语音音效（如狗叫、刹车声、玻璃碎裂）采取了完全不同的策略——只能用粗粒度的通用类别词来描述（比如只写“机械噪音”、“撞击声”或“动物叫声”）。
- 这样做的目的是“避免过度推测”——因为仅凭音频很难100%确定声音的具体来源，强行细描可能引入幻觉。
- 但代价就是：脚本里关于音效的文本信息极其模糊，而QA生成又完全依赖脚本本来“出题”和“找答案”，既然脚本文本对音效的描述都是“大概是什么”，模型在学习时就抓不到精细的声学特征，遇到需要区分“刹车声”和“引擎轰鸣声”的问题时，自然就答不对了。

发消息或按住说话

深度思考 智能搜索

16:07

新对话

图2b显示视频时长平均103秒，那如果超过这个限制，会导致模型出现偏差吗？

好问题！你抓住了论文里一个很隐蔽但很重要的细节。

根据论文正文，超过平均时长（103秒）确实会导致模型表现下降，但原因不是模型“超时崩溃”，而是数据生成和模型处理两个环节都出现了能力衰减。论文里有三处直接证据：

证据1：表2明确显示“视频越长，模型表现越差”

从表2的(0,2)min和(2,5)min两列对比来看：

- Qwen2.5-Omni基线：短视频38.51%、长视频44.77%（反而涨了？别急，看微调后的）
- OmniVideo-7B (Qwen2.5) 微调后：短视频54.66%，长视频63.37%

表面上看长视频分数更高，但注意——基线模型在长视频上本身就表现更好（44.77% vs 38.51%）。

发消息或按住说话

深度思考 智能搜索

16:07

新对话

表面上看长视频分数更高，但注意——基线模型在长视频上本身就表现更好（44.77% vs 38.51%），因为长视频信息更多，瞎蒙也能蒙对更多。真正要看的是“提升幅度”：

- 短视频提升：54.66 - 38.51 = 16.15个百分点
- 长视频提升：63.37 - 44.77 = 18.60个百分点

看起来长视频提升更大？但这是绝对提升。如果看相对提升率：

- 短视频：16.15 / 38.51 = 41.9%
- 长视频：18.60 / 44.77 = 41.5%

两者几乎持平。这说明模型在长视频上没有获得额外优势，信息多了但没被有效利用。

更关键的是VITA-1.5的表现：

- 短视频：39.24 → 59.01，提升19.77个百分点
- 长视频：44.72 → 62.79，提升18.07个百分点

长视频的升幅低于短视频。这说明当视频变长时，微调带来的增益在缩小——模型处理长视频的能力提升不如短视频明显。

发消息或按住说话

深度思考 智能搜索

